


**KARADENİZ TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**



**GPS VERİSİ OLMAYAN ORTAMLARDA GÖRÜNTÜ İŞLEME
TEKNİKLERİ İLE KONUM TESPİTİ YAPILMASI**

BİTİRME PROJESİ TEZİ

**Hüdahan ALTUN
Osman Can AKSOY
Ufuk BULUT**

2023-2024 BAHAR DÖNEMİ



IEEE Etik Kuralları IEEE Code of Ethics



Mesleğime karşı şahsi sorumluluğumu kabul ederek, hizmet ettiğim toplumlara ve üyelerine en yüksek etik ve mesleki davranışta bulunmaya söz verdiğimi ve aşağıdaki etik kurallarını kabul ettiğimi ifade ederim:

1. Kamu güvenliği, sağlığı ve refahı ile uyumlu kararlar vermenin sorumluluğunu kabul etmek ve kamu veya çevreyi tehdit edebilecek faktörleri derhal açıklamak;
2. Mümkün olabilecek çıkar çatışması, ister gerçekten var olması isterse sadece algı olması, durumlarından kaçınmak. Çıkar çatışması olması durumunda, etkilenen taraflara durumu bildirmek;
3. Mevcut verilere dayalı tahminlerde ve fikir beyan etmelerde gerçekçi ve dürüst olmak;
4. Her türlü rüşveti reddetmek;
5. Mütenasip uygulamalarını ve muhtemel sonuçlarını gözeterek teknoloji anlayışını geliştirmek;
6. Teknik yeterliliklerimizi sürdürmek ve geliştirmek, yeterli eğitim veya tecrübe olması veya işin zorluk sınırları ifade edilmesi durumunda ancak başkaları için teknolojik sorumlulukları üstlenmek;
7. Teknik bir çalışma hakkında yansız bir eleştiri için uğraşmak, eleştiriye kabul etmek ve eleştiriye yapmak; hatları kabul etmek ve düzeltmek; diğer katkı sunanların emeklerini ifade etmek;
8. Bütün kişilere adilane davranmak; ırk, din, cinsiyet, yaş, milliyet, cinsi tercih, cinsiyet kimliği, veya cinsiyet ifadesi üzerinden ayrımcılık yapma durumuna girişmemek;
9. Yanlış veya kötü amaçlı eylemler sonucu kimsenin yaralanması, mülklerinin zarar görmesi, itibarlarının veya istihdamlarının zedelenmesi durumlarının oluşmasından kaçınmak;
10. Meslektaşlara ve yardımcı personele mesleki gelişimlerinde yardımcı olmak ve onları desteklemek.

IEEE Yönetim Kurulu tarafından Ağustos 1990'da onaylanmıştır.

ÖNSÖZ

“GPS Verisi Olmayan Ortamlarda Görüntü İşleme Teknikleri İle Konum Tespiti Yapılması” konulu bu çalışma, Karadeniz Teknik Üniversitesi, Bilgisayar Mühendisliği Bölümü’nde “Bitirme Projesi” olarak hazırlanmıştır.

Bu araştırma, elektronik harp durumlarında veya zorlu coğrafi koşullarda mücadele eden insansız hava araçlarının, GPS ile etkileşimi olmadığında dahi konumlarını tespit etmek için geliştirilmiş bir yöntemi ele almaktadır. Görüntü işleme ve derin öğrenme temelli bir metodoloji, bu zorlu durumlarda insansız hava araçlarının konumlarını belirlemede etkili olabilecek bir çözüm önerisi sunmaktadır.

Proje çalışmaları ve araştırma aşamaları boyunca bizlere sunduğu destek ve katkılarından dolayı danışman hocamız sayın Prof. Dr. Murat EKİNCİ ’ye teşekkürlerimizi ve saygılarımızı sunarız.

Hüdahan ALTUN
Osman Can AKSOY
Ufuk BULUT
Trabzon 2024

İÇİNDEKİLER

	Sayfa No
IEEE ETİK KURALLARI	II
ÖNSÖZ	III
İÇİNDEKİLER	IV
ÖZET	V
1. GENEL BİLGİLER	6
1.1. Giriş	6
1.2. SIFT, FLANN ve RANSAC Algoritmalarının Tasarım Projesinde Kullanım Alanları	6
1.3. Geleneksel Keypoint Çıkarım Mekanizmalarının Yetersiz Kalması	7
1.4. SuperPoint: Self-Supervised Interest Point Detection and Description	8
1.5. Geleneksel Keypoint Matcher Mekanizmalarının Yetersiz Kalması	10
1.6. GlueStick: Robust Image Matching by Sticking Points and Lines Together	11
1.7. SuperGlue: Learning Feature Matching with Graph Neural Networks	13
2. PROJE TASARIMI	17
2.1. GEREKSİNİM ANALİZİ	17
2.2. MİMARİ TASARIM	19
2.2.1. Gerçek Şehir Görüntüleri ile Algoritmanın Performans Değerlendirmesi	19
2.2.2. SuperPoint ve SuperGlue ile Gerçek Şehir Görüntüleri Deneme Performansı	20
2.3. UML NESNE MODELİ	22
2.4. RİSK YÖNETİMİ	22
3. KAYNAKLAR	24
4. EKLER	25
STANDARTLAR ve KISITLAR FORMU	26

ÖZET

İnsansız hava aracından elde edilen anlık görüntüler üzerinde görüntü işleme tekniklerini kullanarak özellik çıkarımı (feature extraction) gerçekleştirir. Ardından, hava aracının görev icrasında bulunduğu bölgenin belirli yüksekliklerden önceden çekilmiş ve hafızasında bulunan uydu görüntülerinin özellikleri ile anlık görüntüler arasındaki özellikleri eşleştirerek en doğru homografi matrisi bulunması amaçlanır. Bulunan bu homografi matrisini kullanarak anlık görüntünün ana uydu görüntüsü üzerindeki yerinin saptanması hedeflenir. Bulunan bu veriler ışığında küresel koordinat sisteminde kullanılan enlem ve boylam değerlerine dönüşüm yapılarak harita üzerindeki gerçek zamanlı konumun elde edilmesi hedeflenir.

Elde edilen ön araştırma sonuçları, görüntü işleme temelli konum belirleme metodolojisinin gerçek dünya uygulamaları için umut verici olduğunu göstermektedir. Bu rapor, GPS verisi olmayan ortamlarda konum tespiti konusundaki araştırmalara katkıda bulunmak amacıyla endüstriyel ve akademik alanlara değerli bir inceleme sunmaktadır.

1.GENEL BİLGİLER

1.1.Giriş

GPS olmayan ortamlarda konum tespiti, günümüzün teknolojik gereksinimlerinin yanı sıra askeri operasyonlar gibi kritik alanlarda büyük bir öneme sahiptir. İnsansız hava araçlarının askeri amaçlı kullanıldığı durumlarda, düşman birlikleri elektromanyetik saldırılarla insansız hava aracının GPS ile etkileşimini keserek bu aracı devre dışı bırakma amacı güderler. İnsansız hava aracı böyle bir saldırıya maruz kalınca, konum bilgisini kaybedeceğinden ve kör uçuş yapacağından ötürü, aracın imha edilmesi söz konusu olabilmektedir. Ayrıca olumsuz hava koşulları sebebiyle veya zorlu coğrafi koşullarda görev icra eden hava aracının yine GPS verisi ile erişiminin kesilmesi durumları söz konusu olabilmektedir. Belirtilen bu problemlere karşın sunduğumuz model ise insansız hava aracının kamera sisteminden alınan anlık görüntüleri, görüntü işleme ve derin öğrenme algoritmalarının yardımıyla konum tespiti üzerindeki etkisini araştırarak, alternatif çözümler sunmayı hedefler.


GPS olmadan konum tespiti son yıllarda üzerine düşülen ciddi bir araştırma konusudur. Bu soruna önerilen çözümlerin başında şirketlerin kendi haberleşme altyapısının geliştirilmesidir. Bu haberleşme altyapısı yine elektromanyetik veya kuantum temelli bir yaklaşım olabilmektedir. Buna karşın bu haberleşme altyapısı yine elektromanyetik saldırılar ile çökertilebilir. Önerdiğimiz görüntü işleme ile konum tespiti yaklaşımı daha özgün bir yaklaşımdır. Bu sistem kapalı devre sistemdir. Yani bir sinyal aracılığıyla konum tespiti olmaksızın, tamamen hava aracının donanımsal özelliklerini kullanarak konum tespiti yapabilmektedir. Dışarıdan gelecek haberleşme sistemini bozabilecek herhangi bir saldırıya dirençli yaklaşım sergileyebilmektedir.

Projenin metodolojik olarak sunduğu yaklaşım, görüntü işleme tekniklerinin konum belirleme sürecine entegrasyonunda kuramsal ve pratik anlamda önemli bir adımı temsil etmektedir. Bu çalışma, literatüre, özellikle görüntü işleme ve konum tespiti alanlarına, pratik uygulanabilirlik açısından yeni bir bakış açısı getirmektedir. Jiroskop ve diğer konum tespit sistemleri ile desteklenerek güvenilir ve doğrulanabilir konum tespiti imkânı sunacaktır.

Bu çalışmanın temel araştırma hipotezi, görüntü işleme algoritmalarının GPS etkileşimin olmadığı ortamlarda konum tespiti için ne derece etkili olduğunu, kullanılan algoritmaların hızı, hassasiyetini ve uygulanabilirliğini hangi koşullarda nasıl etkilediğini incelemektir.

1.2. SIFT, FLANN ve RANSAC Algoritmalarının Tasarım Projesinde Kullanım Alanları

GPS olmayan ortamlarda görüntü işleme ile konum tespiti yaparken SIFT, FLANN ve RANSAC algoritmaları kullanılmasına tasarım kapsamında karar kılınmıştır. İlgili projede ana uydu görüntüsüyle, insansız hava aracının belli mesafeden çekmiş olduğu anlık görüntüleri kıyaslayarak, anlık çekilen o görüntünün uydu görüntüsünde nereye karşılık geldiğinin bulunması amaçlanır.



SIFT ile hem uydu görüntüsünün hem de anlık olarak çekilen görüntüdeki keypointler çıkartılır. Uydu görüntüsünden elde edilen keypointler hafızada önceden tutulur. Anlık çekilen görüntüdeki keypointler ile uydu görüntüsündeki keypointlerin eşleştirilmesi için FLANN kullanılır. Eşleşen bu keypointlerin içerisinde yanlış eşleşmeler mevcuttur. Bu yanlış eşleşmeleri ayıklama görevi RANSAC algoritmasına aittir. En doğru keypointleri bulduktan sonra ve doğru eşleşme gerçekleştikten sonra ana uydu görüntüsü içinde anlık çekilen görüntünün konumu bulunur. Sonrasında bu konum coğrafi koordinat sistemi konumuna dönüştürülür.

1.3. Geleneksel Keypoint Çıkarım Mekanizmalarının Yetersiz Kalması

SIFT, FAST ve ORB gibi keypoint çıkarım algoritmaları bilgisayarlı görü alanında en çok bilinen algoritmalar. Tasarım projesi kapsamında SIFT algoritması kullanılmıştı. Tasarım projesinde olduğu gibi karmaşık problemlerin olduğu kısımlarda SIFT algoritmasının yetersiz kaldığı görülmüştü. Dolayısıyla tasarım projesinin bir sonraki adıma taşınması için yeni bir yöntem keşfedilmesi gerekmektedir.

Özellikle son yıllarda keypoint çıkarımı için derin sinir ağları kullanımı popüler olmaya başlamıştır. Universal Correspondence Network (UCN), DeepDesc (Deep Descriptor), TILDE ve LIFT gibi derin öğrenme tekniklerini kullanarak görüntü alt yapılarının (patch) eşleştirilmesini sağlayan farklı derin ağ modelleri mevcuttur. Bu ağlar, aynı veya benzer nesneleri farklı görüntülerde tanımlamak için convolutional sinir mimarisini kullanır.

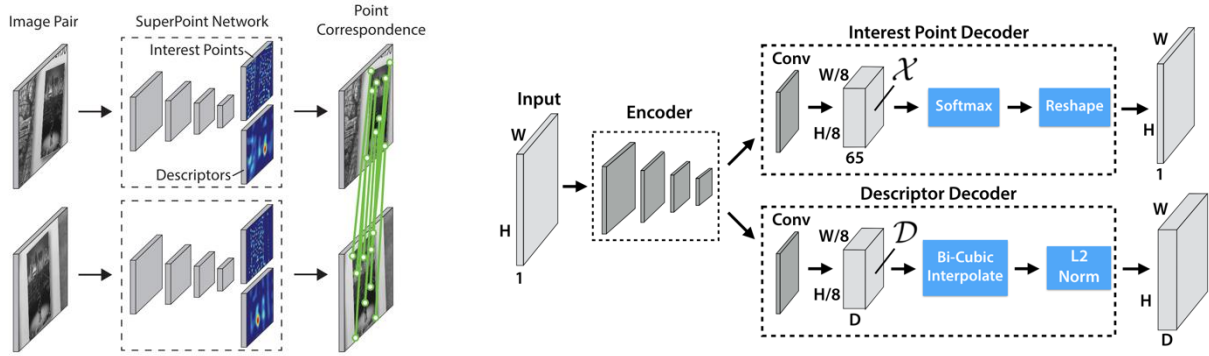
İlgili projemizde keypoint çıkarımını düzgün ve istenilen şekilde yapacak olan algorithmada bazı özellikler aramaktayız.

	InterestPoints	Descriptors	FullImage Input	Single Network	RealTime
SuperPoint	X	X	X	X	X
LIFT	X	X			
UCN		X	X	X	
TILDE	X			X	
DeepSec		X		X	
SIFT	X	X			
ORB	X	X			X
FAST	X	X			

Projemizdeki problemin gerçek zamanlı çalışması önem arz etmektedir. LIFT, UCN, TILDE ve DeepSec ağları bünyelerinde barındırdığı CNN mimarisinin tasarım yapısından ötürü gerçek zamanlı çalışma ihtiyacına cevap vermemektedir. Aynı zamanda projemizde görüntü boyutunda oynama yapmadan işlem yapmakta konum tespiti açısından önem arz etmektedir. UCN ağı bu ihtiyaca cevap vermektedir fakat gerçek zamanlı olmamasından ötürü kullanımı projemizin ihtiyacını karşılamayacaktır.

Bütün bu ihtiyaçlar göz önünde bulundurulduğunda yukarıdaki tabloda görüldüğü gibi ihtiyaçlarımıza cevap verecek olan model SuperPoint'tir. SuperPoint ağı VGG ağları gibi, bir dizi convolutional katman ve ardından gelen fully connected katmanlardan oluşur. Sade ve tekdüze olan mimarisinden ötürü bütün ihtiyaçlara cevap verebilir hale gelmiştir.

1.4. SuperPoint: Self-Supervised Interest Point Detection and Description



SuperPoint, öz-denetimli bir keypoint tespit ve tanımlama sistemidir. Keypoint tespit ve tanımlama, bilgisayarla görü alanında, özellikle Simultaneous Localization and Mapping (SLAM), Structure-from-Motion (SfM), kamera kalibrasyonu ve görüntü eşleştirme gibi görevlerde kritik öneme sahiptir.

SuperPoint, keypoint tespiti ve tanımlaması için tam boyutlu bir görüntü üzerinde çalışabilen derin bir sinir ağı kullanır. Derin öğrenme modellerinde kullanılan ve orta büyüklükte bir karmaşıklığa ve parametre sayısına sahip omurga (medium-size backbone) mimarisini temellidir.

Superpoint giriş görüntüsünün boyutunu işlemek için “Shared Encoder” kullanır. Encoder sonrası mimari Interest Point Decoder ve Descriptor Decoder olarak ikiye bölünür. Adlarından anlaşılacağı üzere biri interest point tespiti diğeri ise descriptor çıkarımı yapar.

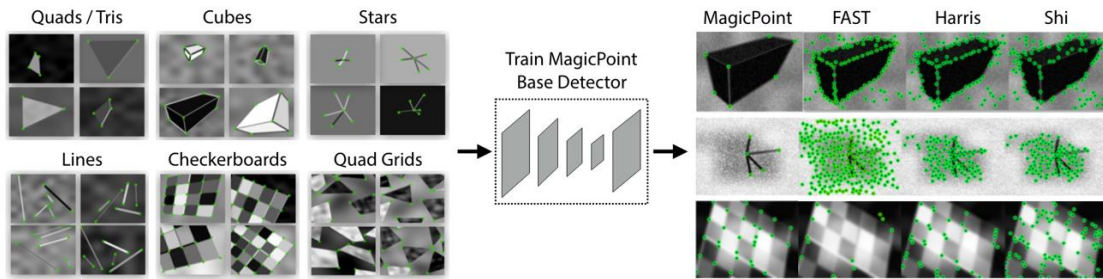
Shared Encoder, VGG tarzı bir kodlayıcı olup görüntü boyutunu azaltmak için kullanılır. Encoder, convolutional katmanlar, spatial downsampling via pooling ve nonlinear activation fonksiyonlarından oluşur. Bu encoder ile $H_c = H/8$ ve $W_c = W/8$ olacak şekilde boyut düşürmeye olanak sağlar. 3 adet 2×2 non-overlapping max pooling işlemi 8×8 piksel hücrelerini barındıran matristeki her bir yapıya “cell” diyoruz.

Interest Point tespiti için, çıktının her bir pikseli, girdideki o piksel için bir “nokta olma” olasılığına karşılık gelir. Yoğun tahmin için standart ağ tasarımı, uzamsal çözünürlüğün

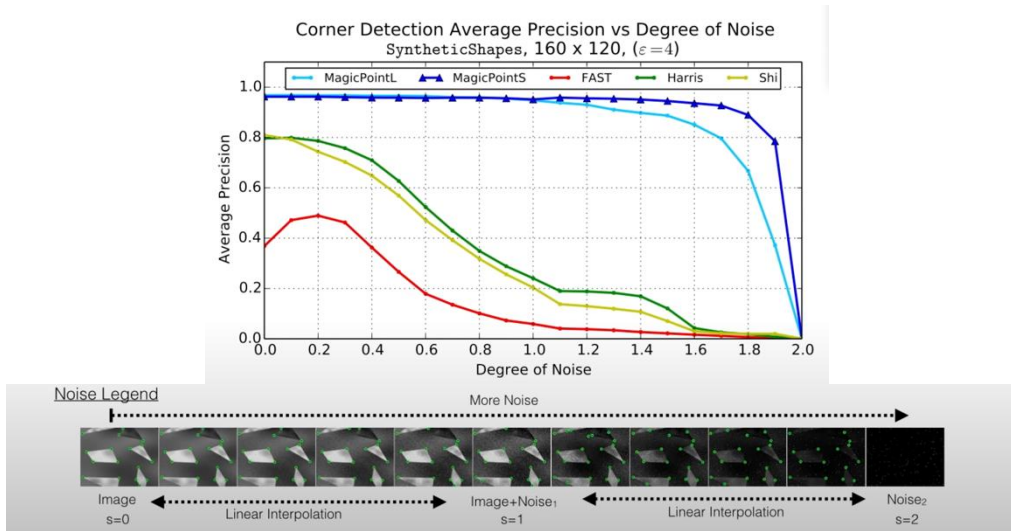
havuzlama veya kademeli konvolüsyon yoluyla azaltıldığı gibi yukarı konvolüsyon işlemleri yoluyla tam çözünürlüğe geri örneklendiği bir kodlayıcı-kod çözücü çifti içerir.

Modelin hızlı olmasını ve eğitimi kolaylaştırmak için kullanılan bir strateji ise boyutunu artırmak için öğrenilmiş ağırlıklar veya parametreler kullanmaz bunun yerine, basit bir büyütme (upsampling) işlemi kullanır. Bu, modelin daha hızlı eğitilmesine ve daha az parametre gerektirmesine yardımcı olur.

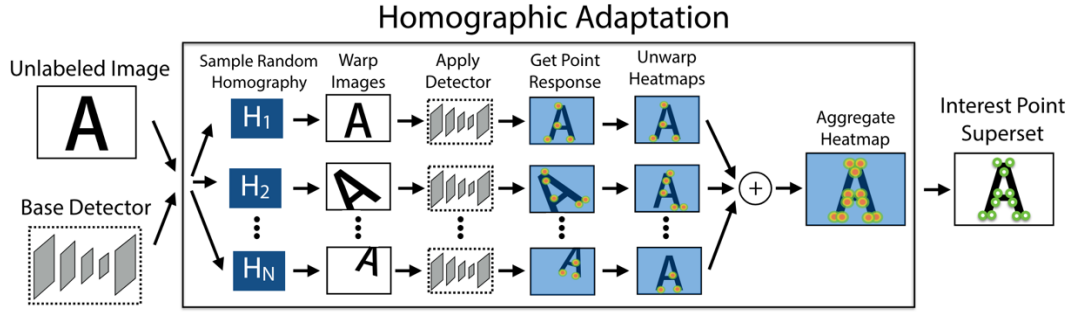
Descriptor head, girişten özellik çıkarır ve $R^{H_c \times W_c \times D}$ boyutunda bir tensör çıkarır. Daha sonra, bu tensör $R^{H \times W \times D}$ boyutunda bir tensöre dönüştürülür. L2-norm ile normalize edilmiş sabit uzunluktaki özellik vektörlerinin yoğun bir haritasını ifade eder. Özellik çıkarmanın yoğunluğunu azaltmak için, model bir yarı yoğun ızgara üretir. Bu, her 8 pikselde bir özellik vektörü üretir. Ardından, model, bu ızgarayı tam yoğunlukta bir ızgaraya dönüştürür ve özellik vektörlerini L2-norm ile normalize eder.



Superpoint ağının eğitimi için günümüzde keypoint etiketli görüntülerden oluşan geniş bir veri tabanı bulunmamaktadır. Bu nedenle, bu ağı eğitmek için önce büyük ölçekli bir sentetik veri kümesi oluşturuyoruz. Eğitim için öncelikle dörtgenlerin, üçgenlerin sentetik veri oluşturma yoluyla basitleştirilmiş 2B geometriden oluşan “Sentetik Şekiller” adlı büyük ölçekli bir sentetik veri kümesi yaratılır ve bu veriler üzerinde eğitim gerçekleştirilir.




Sentetik veri kümesindeki eğitim sonucunda elde edilen ağırlıklar ile bu ağı gerçek görüntü verilince beklenen performans elde edilememektedir. Bu yüzden bu yaklaşıma ek olarak “Homografik Adaptasyon Tekniği” geliştirilmiştir.



Homografi Adaptasyon Tekniği aslında self-training mantığı ile çalışan, gereksiz keypointleri elimine etmek ve güçlü keypointleri öne çıkaran bir yaklaşımdır. Bu yaklaşımda gerçek görüntüleri farklı rotasyonlar ile ağı verip güçlü keypointleri tespit edip bunların pekiştirilmesiyle orijinal görüntü üzerinde nihai keypointler tespit edilir.

Nihai sonuçlara bakacak olursak Superpoint keypoint tespit algoritmasının geleneksel keypoint tespit algoritmalarına karşı bariz üstünlüğü görülmektedir.



1.5. Geleneksel Keypoint Matcher Mekanizmalarının Yetersiz Kalması

Bitirme projesi kapsamında keypoint tespiti için gerekli olan algoritma kadar farklı zamanlarda elde edilen aynı bölgeyi içeren iki görüntü üzerindeki keypointlerin doğru eşleşmesi ciddi önem arz etmektedir. Tasarım kapsamında FLANN match algoritmasının yetersiz kalması derin öğrenme temelli yeni yaklaşımların bulunması gerektiğinin fikrini bize sağlamıştır. Bu yüzden bu işlemi gerçekleştirmek için var olan ağların araştırması yoluna koyulduk. Bulmamız gereken ağların keypoint tespitinde Superpoint algoritmasını kullanması gerekmektedir. Araştırmalarımız sonunda SuperGlue ve GlueStick adında 2 farklı ağ bulduk.

1.6. GlueStick: Robust Image Matching by Sticking Points and Lines Together

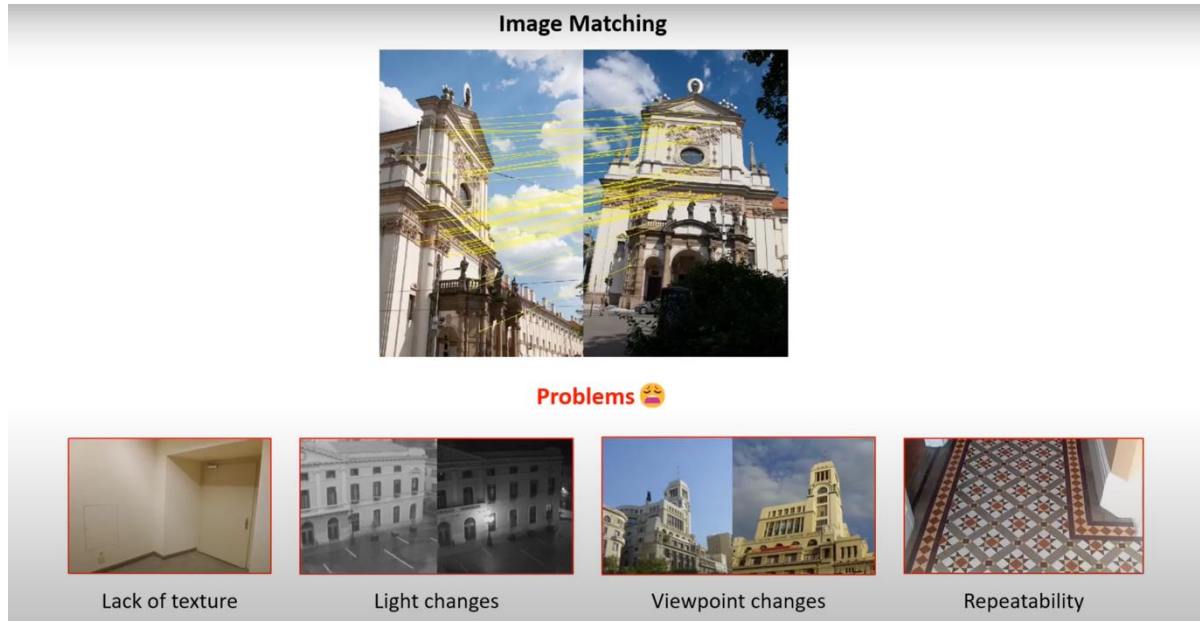
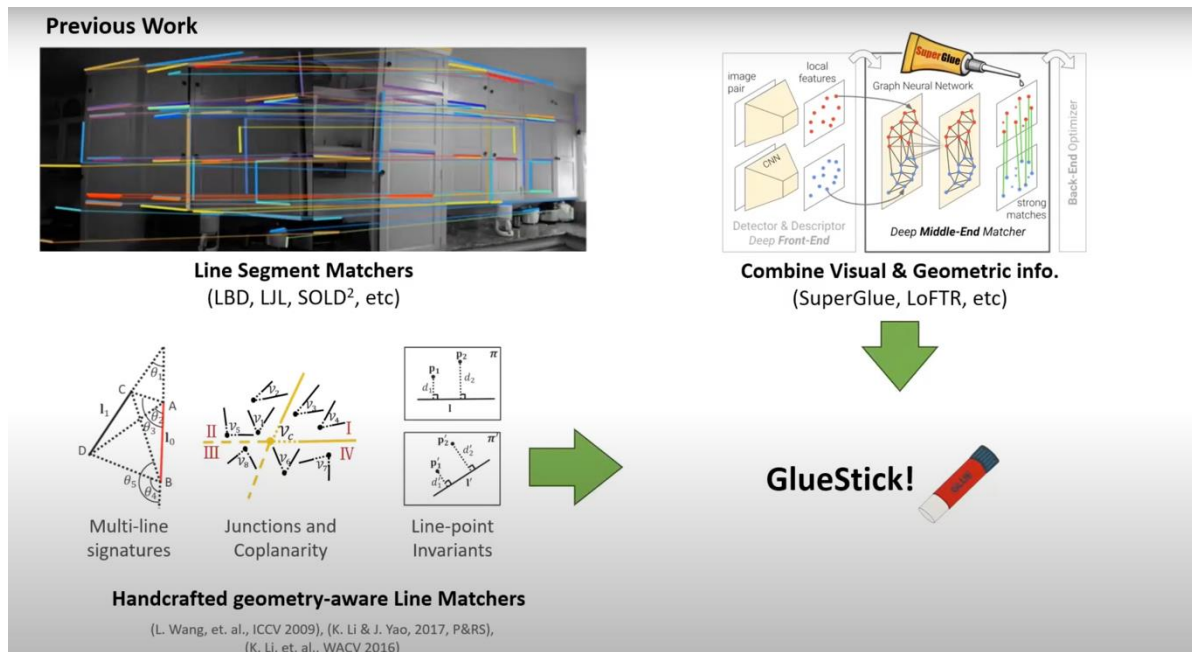
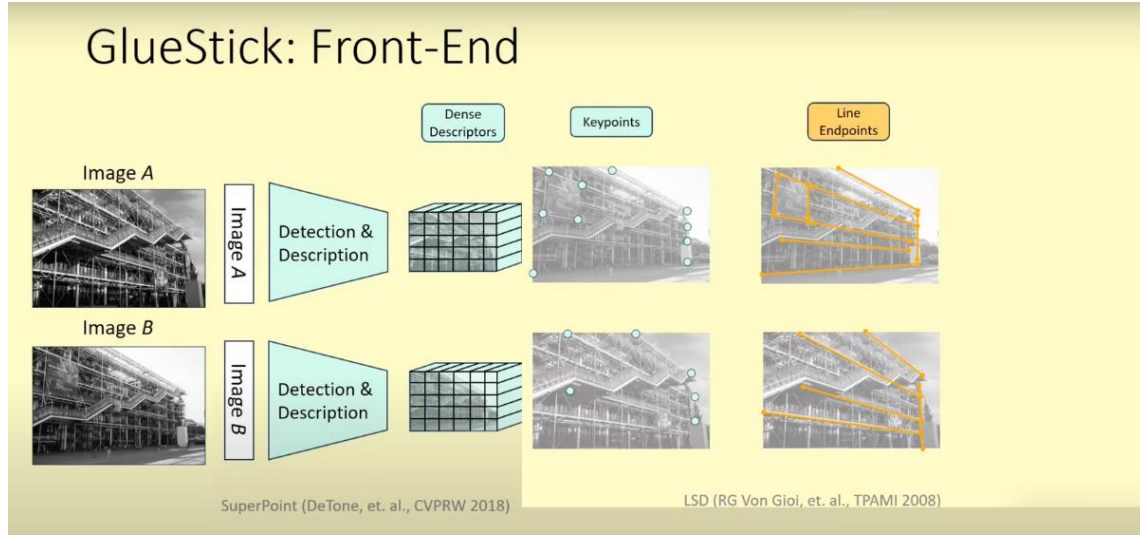


Image Matching'te eşleme yapabilmek için bulunan keypoint adı verilen özet tanımlayıcılar mevcuttur. Bu keypointlerin çıkarımı düz zeminlerde, ışık değişimi olan kısımlarda, bakış açısının değiştiği görsellerde ve tekrarlı grafiklerin barındığı resimlerde gayet zordur.

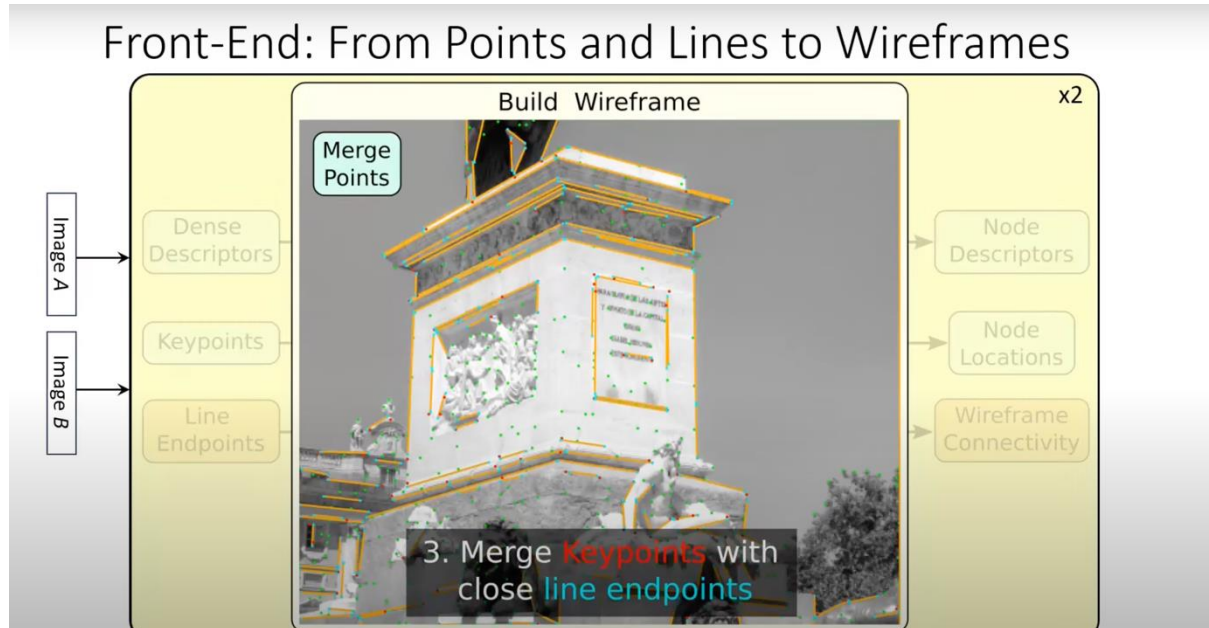
Bunun için line segment adı verilen keypoint yaklaşımı öne sürülür. Bu yaklaşımda resim içerisinde line araması yapılması gerekir. Line bulmanın bazı dezavantajları vardır. Line'ların dokusu resim içerisinde yeterince iyi olmayabilir aynı zamanda başka yapılar bu line'ları kamufle edebilir ve daha önemlisi bir line'ın başlangıç ve bitiş noktasını bulmak ayrı bir problem haline gelebilmektedir.



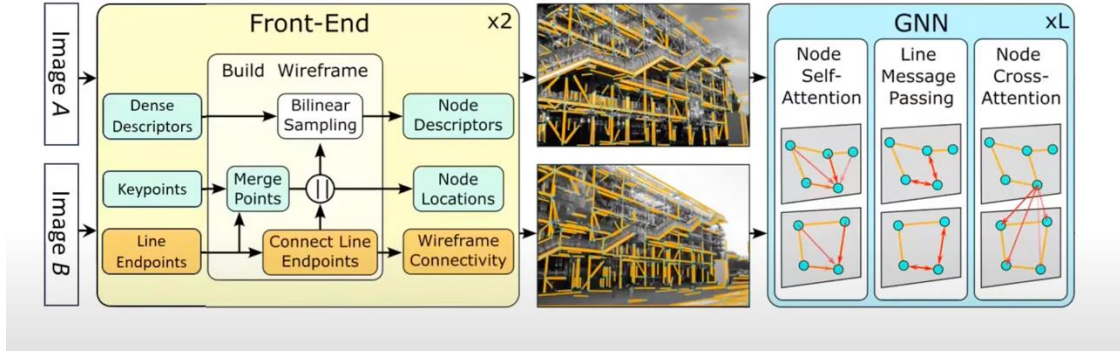
Görüntü içerisinde line çıkarımı için LBD, LJI, SOLD, rough gibi yaklaşımlar kullanılır. Line çıkarımını daha iyi yapmak için bu yaklaşımlar ile keypointlerin geometrik dizilimini bir araya getiririz.



Giriş olarak 2 tane görüntü verilir ve CNN ile bunların keypointleri çıkartılır. Bu keypointler aslında Superpoint ağı ile elde edilir. Sonra LSD ile line çıkarımı yapılır.



Keypoint ve line'ların birleşimine "wireframe" denir. Line'lar ve edge'lerin çıkarımı burada yapılmıştır. Bu kısım GlueStick'in front-end kısmını oluşturur.



Line segment, SLAM, poz tahmini, construction monitoring ve 3B yeniden yapılandırma gibi çok çeşitli bilgisayarla görme görevlerinde yararlı olan üst düzey geometrik yapılardır. Çizgiler yapılandırılmış sahnelerde her yerde bulunur ve noktasal keypointlerde daha güçlü kısıtlamalar sunar. Özellikle çizgiler, nokta tabanlı yaklaşımların zorlandığı düşük dokulu sahnelerde göze çarpar. Bununla birlikte, kilit noktalarla karşılaştırıldığında, line segmentleri genellikle görüntüde zayıf bir şekilde konumlandırılır ve malesef görsellerde bulunma miktarı daha azdır. Line segmentlerini tanımlamak da daha zordur çünkü görüntüde geniş bir uzamsal alanı kapsayabilirler ve bakış açısı değişiklikleri nedeniyle oklüzyonlardan ve perspektif etkilerinden muzdariptir. Ayrıca, line'lar genellikle görüntünün bir parçası olarak görünür. İnsan yapımı ortamlarda tekrarlayan yapılar, bu da klasik tanımlayıcı tabanlı eşleştirme başarısız olur. Bu sebepten dolayı, karşılıklı en yakın komşu gibi tipik eşleştirme sezgiselleri ve Lowe'un oran testi genellikle çizgiler için daha az etkilidir. Son zamanlarda, derin öğrenme yeni bir yaklaşım başlatmıştır Graph Sinir Ağları kullanarak keypoint eşleştirme için son zamanlarda kullanılmaya başlanmıştır.


GNN ağları ile tahmin edilen eşleşmelerin yüksek hassasiyet ile saptar ve bu da eşleştirme sezgisellerine ve hatta aykırı değer kaldırma (RANSAC) tekniklerine olan ihtiyacı ortadan kaldırmaktadır. Bunu başarmanın kilit bileşenlerinden biri, anahtar noktaların doğrudan ağdaki konumsal kodlamasından yararlanmak ve görsel özellikleri geometrik bilgilerle birleştirmesine izin vermektir. GNN'nin tüm özelliklerle aynı anda akıl yürütmesine izin vermek, ek bağlam getirir ve tekrarlayan yapıları belirsizleştirir.

Line segmentlerin geniş kapsamı ve tekrarlanabilirlikten yoksun olmaları, onlar için iyi bir özellik temsili bulmayı zorlaştırmaktadır. GlueStick ağını eğitme gibi fırsatımız olmadığı için hazır Oxford-Paris, Megadepth gibi önceden eğitilmiş model üzerinde denemeler yapmak zorunda kalınmıştır. Eğitilmiş modeller ise hep bina, yol, heykel gibi şehirsiz alanlardaki yapılar ile eğitildiği için bu yapıların olmadığı ortamlardan elde edilecek olan İnsansız Hava Aracı görüntüleri ile uydu görüntüleri arasındaki eşleşmeler başarısız olarak sonuçlanmıştır. Bu durum sebebiyle projemizde bu ağı kullanılmaması gerektiğine karar verdik.

1.7. SuperGlue: Learning Feature Matching with Graph Neural Networks

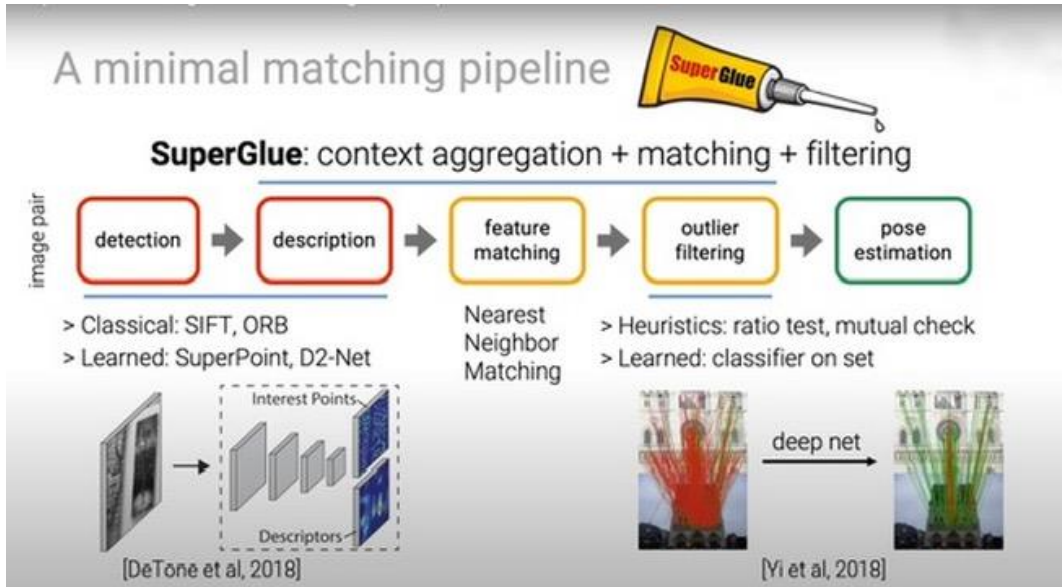
Görüntüler arasındaki noktalar arasındaki karşılıklı ilişkiler, SLAM ve SfM gibi geometrik bilgisayarlı görüş görevlerinde 3D yapıyı ve kamera konumlarını tahmin etmek için temel içeriklerdir. Bu tür karşılıklar genellikle veri eşleştirme olarak bilinen süreçte local feature'ların eşleştirilmesiyle tahmin edilir. Geniş bakış açısı, görüntünün aydınlatılma farklılığı, başka nesnenin diğer nesneyi örtmesi, bulanıklık ve doku eksikliği gibi kavramlar 2D'den 2D'ye veri eşleştirmeyi özellikle zorlu kılan faktörlerdir.

Değişik eşleştirme algoritmaları veya daha iyi detaylı bilgi içeren local feature'lar geliştirmek yerine, SuperGlue adı verilen yeni bir sinir mimarisi bu eşleştirme sürecini önceden var olan local feature'lardan öğrenmeyi hedeflemektedir. Genellikle keypoint çıkarımı sonrası match işleminde SuperGlue ağı yer alır.




SuperGlue yaklaşımı, kullanıma hazır olan local feature'lardan noktasal eşleştirmeler oluşturur. Superglue bir middle-end olarak front ve back arasına yerleştirilir.

SuperGlue, eşleştirme optimizasyon problemini çözmek için Graph Neural Network kullanır ve kısmi nokta görünürlüğü ve örtme gibi zorlukları uygun bir şekilde ele alır.




Geleneksel yöntemlerde bir resim çiftinde öncelikle keypointler tespit edilir ve keypoint descriptorları belirlenir. Bu işlemler için klasik detectorlar olarak SIFT, ORB, FAST kullanılırken, SuperPoint veya D2-Net convolutional neural network kullanarak gerçekleştirilebilir. Sonrasında iki resim arasındaki keypointler nearest neighbor yaklaşımıyla eşleştirilir. Çoğu zaman bu eşleştirmeler başarısız olur bu yüzden sezgisel veya öğrenimli yaklaşımlarla bu eşleştirmeler tekrar filtrelendir. Son olarak RANSAC ile homografi matrisi elde edilir. SuperGlue ise içerik birleştirme, eşleme ve filtreleme işlemlerini tek başına üstlenir. En son olarak RANSAC algoritmasına keypointler verilerek düzgün geometriye sahip olmayan keypointler elenir ve nihai homografi matrisi elde edilir.

The importance of context



Bu ağda, learning feature matching, iki farklı kümedeki local feature'lar arasında kısmi atama (partial assignment) bulma olarak görülür. Lineer bir eşleştirme problemi çözümünde klasik Graph tabanlı eşleştirme işlemini tekrar gözden geçirilir ve bu durumda, optimal taşıma problemine gevşetildiğinde, diferansiyel olarak çözülebilir. Bu optimizasyonun maliyet fonksiyonu (cost function), bir Graph Sinir Ağı (GNN) tarafından tahmin edilir. Transformer'ın başarısından ilham alınarak, öz-dikkat (iç-görüntü) ve çapraz-dikkat (ara-görüntü) kullanarak, anahtar noktaların hem mekansal ilişkilerinden hem de görsel görünümünden yararlanır. Bu formülasyon, tahminlerin atama yapısını zorlarken, maliyetin karmaşık önceliklerini öğrenmesine izin verir böylece örtme ve tekrar edilmeyen anahtar noktaları zarif bir şekilde ele alır. Yöntemimiz, görüntü çiftlerinden uçtan uca eğitilir. Büyük bir etiketli veri setinden poz tahmini için öncelikler öğreniriz, SuperGlue'un 3D sahne ve atama hakkında akıl yürütmesine olanak tanır. Çalışmamız, yüksek kaliteli özellik eşleştirmeleri gerektiren çeşitli çoklu görüş geometri sorunlarına uygulanabilir.

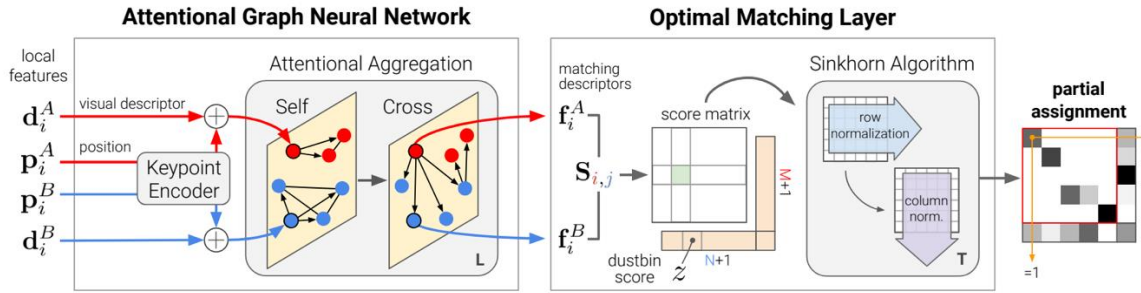


SuperGlue girişi iki farklı görüntüdeki keypointlerden elde edilen \mathbf{P}_i ve \mathbf{D}_i verileridir. Çıktısı ise her bir hücresi 0-1 aralığında olan $M \times N$ 'lik bir matristir ve satır veya sütunların değerlerinin toplamı 1'den azdır. Bulunan bu matrix "Soft Partial Assignment Matrix" olarak adlandırılır.

SuperGlue'nun hem geleneksel matcher'lara hem de öğrenen sınıflandırıcılara göre üstünlüğünü öne çıkılmaktadır. Deep front-end olan SuperPoint ile birleştirildiğinde, SuperGlue, iç ve dış mekan tahmini görevlerinde mevcut en iyi durumu ileri taşır.

Graph eşleştirme problemleri genellikle NP-zor olan, pahalı, karmaşık ve dolayısıyla uygulanması zor çözümler gerektiren kare matris atama problemleri olarak formüle edilir. 2000'lerin bilgisayar görüşü literatürü, yerel özellikler için birçok sezgisel kural içeren el yapımı maliyetler kullanırken, bu yaklaşım karmaşık ve kırılımandır. SuperGlue ise derin bir sinir ağı kullanarak esnek bir maliyet öğrenir.

Görüntü eşleştirme problemi, dünyanın bazı düzenliliklerinden yararlanabilir. 3D bir dünya genellikle düzgündür ve bazen düzlemseldir. Sahne sabitse belirli bir görüntü çifti için tüm eşleştirmeler tek bir epipolar dönüşten türetilir ve bazı pozlar diğerlerinden daha olasıdır. Ayrıca, 2D keypointler genellikle köşeler veya bloklar gibi belirgin 3D noktalarının yansımalarıdır, bu nedenle görüntüler arasındaki eşleştirmeler belirli fiziksel kısıtlamalara uygun olmalıdır: I) bir keypoint diğer görüntüde birden fazla keypoint ile eşleşebilir. II) Bazı keypointler, sift, orb gibi detectorun başarısızlığından dolayı veya occlusion hatasından dolayı eşleşmeyebilir. Etkili bir feature matcher modeli, aynı 3D noktaların yeniden yansımaları arasındaki tüm eşleştirmeleri bulmayı ve eşleşmeyen anahtar noktaları tanımlamayı amaçlamalıdır.



SuperGlue mimarisi Attentional GNN ve Optimal Matching Layer olmak üzere iki ana kısımdan oluşur. İlk katman iki farklı görüntüden alınan p verisi için keypoint endcoder ile bir çeşit işleme sokar ve kendi d 'leri ile tek bir vektöre çevirir. Sonra bu vektör GNN'e verilerek self ve cross attention layer katmanlarını da kullanarak her iki görüntü için ayrı "f" adından güçlü bir temsilci yaratır. İkinci katman ise $M \times N$ 'lik bir matris yaratır sonra dustbin score denen şey ile ekstra satır ve sütun ekleyerek $(M+1) \times (N+1)$ lik matris oluşur ve sonra Sinkhorn algoritması ile optimum eşleşme bulunur.

Yukarıdaki kısımdaki I ve II olayları, karşılıklılıkların iki anahtar nokta kümesi arasında kısmi bir atamadan türetilmesi anlamına gelir. Aşağı akış görevlere entegrasyon ve daha iyi yorumlanabilirlik için, her olası karşılıklılığın bir güven değeri olmalıdır. Sonuç olarak bir kısmi yumuşak atama matrisi tanımlar.

define a partial soft assignment matrix $\mathbf{P} \in [0, 1]^{M \times N}$ as:

$$\mathbf{P} \mathbf{1}_N \leq \mathbf{1}_M \quad \text{and} \quad \mathbf{P}^\top \mathbf{1}_M \leq \mathbf{1}_N. \quad (1)$$

Bir keypointin konumu ve görsel görünümü dışında, diğer bağlamsal ipuçlarını ona entegre etmek, onun farklılığını sezgisel olarak artırabilir. Örneğin, dikkate alınabilecek diğer co-visible keypoint olan mekansal ve görsel ilişkisi, öne çıkan, benzer, istatistiksel olarak birlikte ortaya çıkan veya bitişik olan noktalar gibi. Diğer yandan, ikinci görüntüdeki keypointlerin bilgisi, aday eşleşmeleri karşılaştırarak veya küresel ve belirsiz ipuçlarından fotogrametrik veya geometrik dönüşümü tahmin ederek belirsizlikleri çözmeye yardımcı olabilir. Belirsiz bir keypointin eşleştirilmesi istendiğinde, insanlar her iki görüntüye de ileri-geri bakarlar ve böylece kesin olmayan eşleştirme keypointlerini elemeye çalışırlar. Böylece her

birini inceleyerek, gerçek eşleşmeyi diğer benzerliklerden ayırmaya yardımcı olan bağlamsal ipuçlarını ararlar. Bu, olay belirli konumlara odaklanabilen bir iteratif bir süreci işaret eder. Bu nedenle, SuperGlue'un ilk önemli bloğunu, bir Attentional Graph Neural Network olarak tasarlarız. İlk local feature'lar verildiğinde, özelliklerin birbirleriyle iletişim kurmasına izin vererek eşleşme tanımlayıcılarını $f_i \in \mathbb{R}^D$ hesaplar. Göstereceğimiz gibi, görüntüler içinde ve arasında uzun menzilli özellik birleşimi, sağlam eşleşme için hayati öneme sahiptir.

İki görüntünün keypointlerinden oluşan bir tam graph düşünelim. Graph, iki tür yönsüz kenara sahip olsun yani birleşik bir graph olsun. Self Edges (Eself), i keypointleri aynı görüntü içindeki diğer tüm anahtar noktalarına bağlar. Cross Edges (Ecross) ise i keypointleri diğer görüntüdeki tüm anahtar noktalara bağlar. Backpropagation (ağırlık güncellemesi) için message passing formülasyonunu kullanılır. Ortaya çıkan Multiplex GNN ağı, yüksek boyutlu bir durumla başlar ve her katmanda, tüm düğümler için verilen tüm kenarlar boyunca mesajları eşzamanlı olarak toplayarak güncellenmiş bir temsil hesaplar.

SuperGlue ağını eğitme imkanına sahip olmadığımız için “outdoor trained” adı verilen önceden eğitilmiş modelini projemizde kullanmaktayız. Bu model gerçek görüntü ile uydu görüntüsü arasındaki keypoint eşleştirmede gözle görülür başarılı sonuçlar verdiği için projemizde bu ağın kullanılması uygun görülmüştür.

2.PROJE TASARIMI

2.1. Gereksinim Analizi

Bu projede, GPS erişiminin sınırlı olduğu veya hiç olmadığı durumlarda görüntü işleme teknikleriyle insansız hava aracının konumunu tespit etmeyi hedeflenmektedir. Bu amaç doğrultusunda izlenecek yöntemler şu şekilde planlanmıştır:

1. Benzer Uygulamaların İncelenmesi:

- Türk Savunma Sanayii firması olan STM'nin KERKES projesi ve TUALCOM'un TRNAV adındaki çalışması gibi benzer projelerin incelenmesi ve bu teknolojilerin hangi metodolojileri kullandığının anlaşılması. KERKES, insansız hava araçlarının haberleşmenin olmadığı durumda, sensörlerden alınan veri ve görüntüler işlenerek konum kestirimi yapılabilen projedir. TRNAV, GPS alternatifi olan yerli imkanlara geliştirilen elektromanyetik haberleşme sistemidir.

2. STM ve TUALCOM'dan Farklı Yaklaşımlar:

- Projemizde, STM'nin geliştirme tarzına yakın bir yaklaşım izlenecektir. Projenin gerçek hayata uygulanabilirliği Python ve OpenCV gibi kütüphaneler ile test edildikten sonra, ilgili algoritmaların gerçek hayatta çözüme ulaştırılması ve bunların ham C++ kodlarıyla tam bağımsız geliştirilmesi hedeflenmektedir. Bu sayede tamamen bize ait olan bir sistem gerçekleştirilmesi amaçlanmaktadır.

3. Sistem Girdileri ve Çıktıları:

- İnsansız hava aracının hafızasında önceden bulunan uydu görüntüleri ve dahili kamerası tarafından anlık çekilen görüntüler, sistemimizin girdilerini oluşturacaktır. Anlık çekilen görüntüler ile hafızadaki görüntüler karşılaştırılıp eşleşme yapılacak ve çıktı olarak, harita üzerinde insansız hava aracının anlık konum verileri elde edilecektir.

4. Dış Donanım, Yazılım ve Haberleşme Arayüzleri:

- Görüntü işleme algoritmalarının geliştirilmesi ve prototip bir ortamda başarılı sonuçlar elde edilmesi amaçlanmaktadır. Algoritmanın başarısının ardından ilgili insansız hava aracının konumunun takip edilebileceği bir arayüz geliştirilmesi hedeflenmektedir. Gerçek hayata uygulanabilmesi için ise kısıtlı bir bölgede insansız hava aracı ile uçuş yaparak eş zamanlı konum tespiti sağlayabilmektir.

5. Kullanıcının Gereksinimi Olan Bütün Görevler:

- Öznitelik çıkarımı, özniteliklerin eşleştirilmesi, konum verisi aktarımı, konum takip arayüzü gibi aşamaların detaylı bir şekilde planlanarak gerçekleştirilmesi hedeflenir.

6. Zaman Kısıtlaması:

- Projenin istenilen sürede tamamlanması için belirlenen görev parçaları ve süreç takvimi.

7. Güvenlik ve Kararlılık:

- Görüntü işleme algoritmalarının güvenliği ve kararlılığı için algoritmaların belirli durumlar altında etkilenmemesi sağlanacaktır.

8. Proje Planı ve İş Paketleri:

- Superpoint ve SuperGlue algoritmalarının kullanılması, öznitelik çıkarımı, eşleştirme ve sonuçların haritalandırılması.

Bu yaklaşım, projenin temel yöntemlerini ve uygulama stratejisini net bir şekilde belirtir, bu sayede projenin geliştirme sürecini daha açık bir şekilde planlanması hedeflenir.

Projenin sistem mimarisinin geliştirilmesi üzerine çalışmalar tamamlanmış olup proje süreci boyunca kullanılacak yapılar ve algoritmalar belirlenmiştir. Bu süreçte proje boyunca yapılacak olan stratejik planlamalar tamamlanmış olup, olası riskler doğrultusunda proje üzerinde ne gibi değişikliklerin yapılabileceği belirlenir.

2.2. Mimari Tasarım


Bitirme kapsamında projemiz SuperGlue ağını temel alarak ilerlemektedir ve gerçek hayata olabildiğince uygulanabilmesi hedeflenmiştir. Tasarım kapsamında elimizde olan algoritmalar gerçek görüntü ve uydu görüntüsü arasında eşleştirmeleri başarısızlıkla sonuçlanıyordu. SuperGlue’yu test edebilmek için ilk olarak Youtube üzerinden LosAngeles şehri üzerinde uçurulan drone görüntüsü ve uydu görüntüsü kullanılacaktır. İkinci olarak Tübitak 2209-A desteği kapsamında ödenek aldık. Bu ödenek ile kendi insansız hava aracımızı temin ettik. Bu insansız hava aracını kendimiz uçurarak en son yerel görüntüleri elde etmeyi ve bunları hem uydu fotoğrafları hem de yine insansız hava aracının daha yüksek irtifadan çekmiş olduğu görüntüler ile eşleştirme işlemlerini gerçekleştireceğiz.

2.2.1. Gerçek Şehir Görüntüleri ile Algoritmanın Performans Değerlendirmesi


Gerçek insansız hava aracı görüntüleri üzerinde uygulama testleri gerçekleştirilmiştir. Bu görüntüler YouTube üzerinden alınmış görüntülerdir. Bu kısımda beklenen bir risk analizi sonucu olarak uygulama son hali ile tamamen doğru bir çalışma göstermemiştir. Bunun sebebi ise SIFT Algoritmasının bu görüntüler üzerinde yetersiz kalmasıdır. Her görsel için çıkartılan feature yapısı gerçek görüntüler için başarılı olamamıştır. Bunun için görüntüler üzerinden daha derin bir özellik çıkartma algoritması uygulanmasının gerekliliği tespit edilmiştir. Bu kısımda SIFT algoritması yerine Deep Learning Network (Derin Öğrenme Ağları) ile birlikte daha önceden oluşturulmuş veri seti üzerinden derin öğrenme yardımı ile birlikte feature çıkartma işleminin gerçekleştirilmesinin gerekli olduğu kanaatine varılmıştır.



Ankara Kızılay Meydanı Görüntüsünün Test Sonucu




Arazi Üzerindeki Alanın Konum Tespit Testi



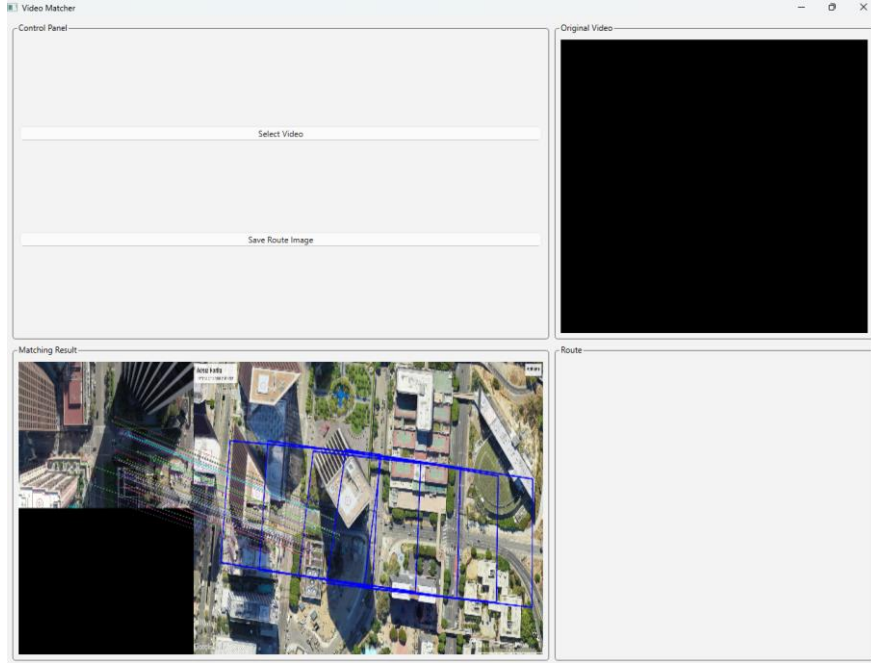
Rize Meydan Görüntüleri ile Yapılan Test Sonuçları

2.2.2. SuperPoint ve SuperGlue ile Gerçek Şehir Görüntüleri Deneme Performansı

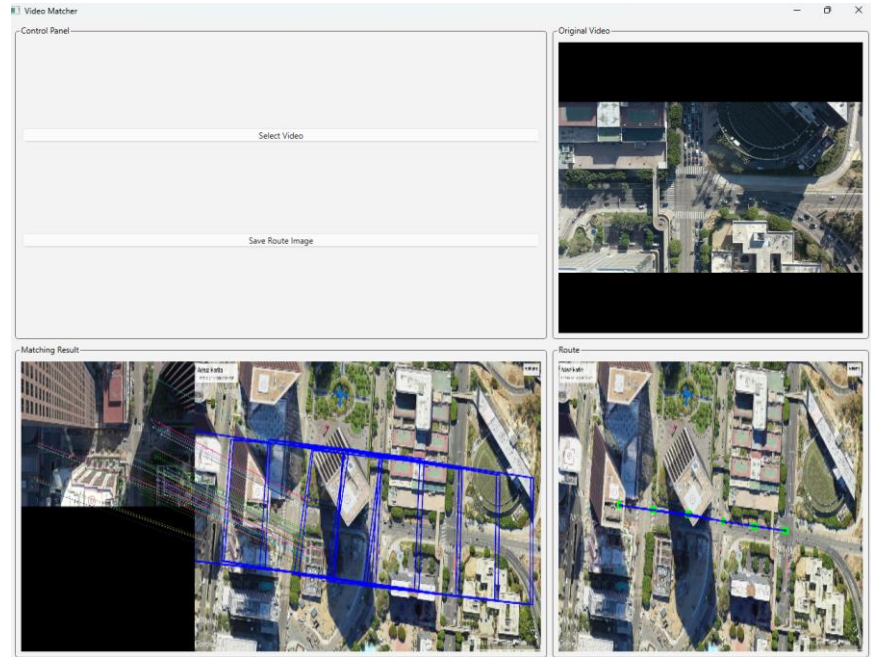
SuperGlue ve SuperPoint algoritmalarını denemek için Los Angeles şehrinin uydu görüntüsünü ve bu şehrin drone ile çekilmiş kuş başı videosunu kullanacağız. Deneme için kullanılacak arayüz uygulamasının açıldığı andaki görüntüsü aşağıdaki gibidir:



Arayüzde “Select Video” butonuna basıp drone görüntümüzü arayüze ekliyoruz. Kod içerisinde bulunan ilgili bölgenin SuperPoint noktaları çıkartılacak ve arayüz sırayla önce SuperPoint daha sonra SuperGlue algoritmalarını çalıştırarak hesaplama yapmaya başlayacaktır. Hesaplama yaparken programın ana videodan çıkarttığı frame’lerin işlenme görüntüsü sol alt kısımda anlık olarak gösterilmektedir.



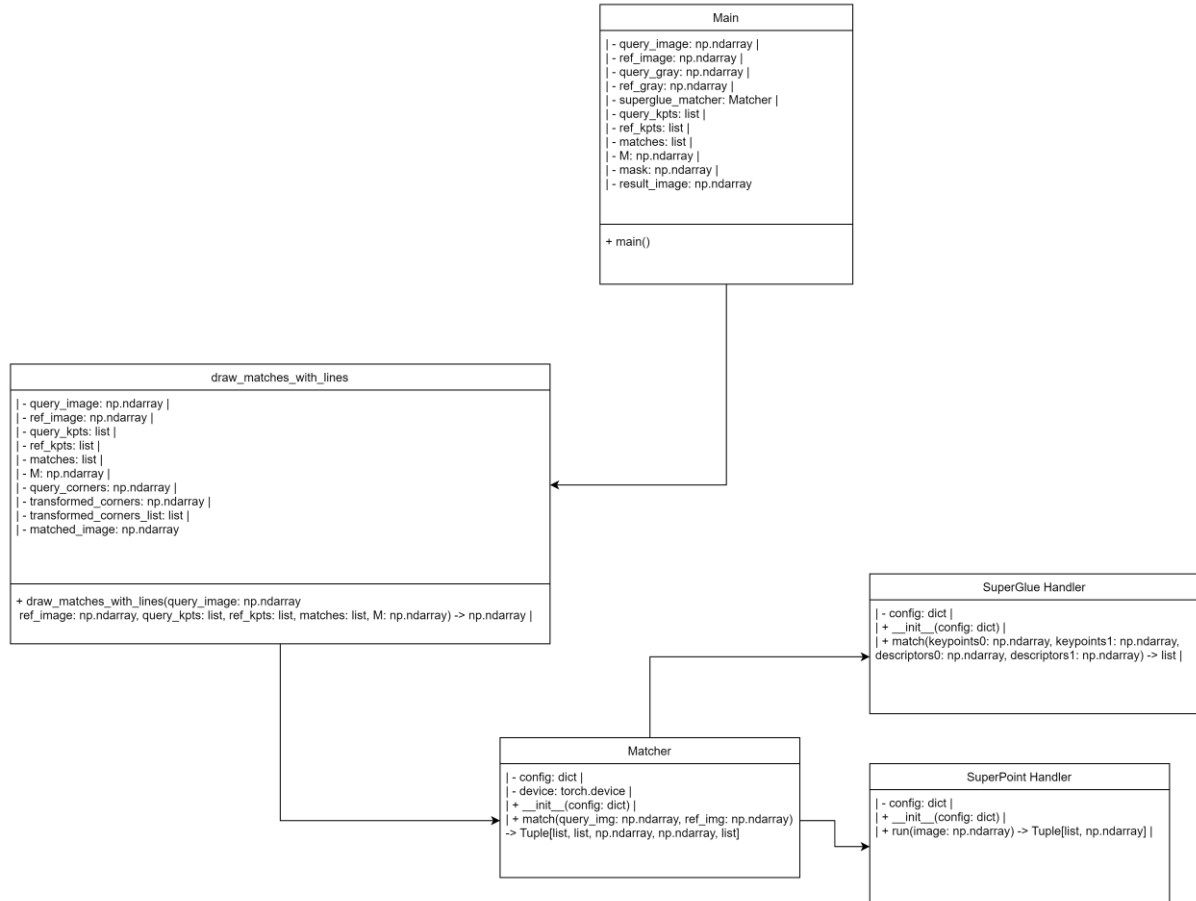
Uygulama tamamlandıktan sonra sağ alt kısımda drone güzergahı belirlenmiş olup sağ üst kısımda ise işlenen videonun canlı görüntüsü ile arayüz üzerinden kontrol sağlanabilmektedir.



Yapılan denemelerde uydu görüntüsü ile gerçek görüntünün eşleştirilmesinde yapay sinir ağlarının başarılı olduğu görülmektedir.

2.3. UML Nesne Modeli

İlgili projenin gerçekleştirilmesi için tasarlanan yazılım sisteminin UML diyagramı aşağıda mevcuttur.



2.4 RİSK YÖNETİMİ

RİSK YÖNETİMİ TABLOSU

İP No	En Önemli Riskler	Risk Yönetimi (B Planı)
1		<p>Görüntü kalitesinin iyileştirilmesi:</p> <p>Görüntü kalitesinin iyileştirilmesi algoritmaların doğruluğunu artırmaya yardımcı olabilir. Görüntüdeki gürültü azaltılabilir, keskinleştirme yapılabilir ve görüntünün kontrastı artırılabilir.</p>

	<p>Algoritmaların etkinliğinin belli koşullarda yetersiz kalması</p>	<p>Işık koşullarının iyileştirilmesi:</p> <p>Işık koşullarının iyileştirilmesi algoritmaların doğruluğunu artırmaya yardımcı olabilir. Projenin gerçekleştirileceği ortamda uygun ışıklandırma koşulları sağlanabilir.</p> <p>Rotasyon ve Ölçeklemeden Bağımsızlık:</p> <p>Hava aracından elde edilen görüntülerin farklı rotasyon ve ölçek durumunun elimine edilip, hafızadaki uydu görüntüsün ile karşılaştırmada hata payını düşürmek.</p> <p>Görüntülenen Ortamın Değişkenliği:</p> <p>İnsansız hava aracının hafızasındaki ana görüntü sabit uydu görüntüsüdür. Anlık çekilen görüntülerde görüntülenen bölgedeki mevsimler, yapısal veya gün ışığına bağlı değişiklikler ana görüntüde eşleme yapmayı zorlaştırabilir.</p> <p>Görüntülenen Ortamın Hava Durumu:</p> <p>İnsansız hava aracının görev yaptığı bölgede yağış, rüzgâr, sis, ve alçak bulutlar sebebiyle elde edilen anlık görüntülerde ciddi bozulmalar meydana gelebilir.</p>
2	<p>Veri setinin yetersizliği</p>	<p>Projenin başarılı olabilmesi için yeterli miktarda ve çeşitlilikte veri setine yani uydu görüntüsü ve anlık olarak çekilen görüntülere ihtiyaç vardır. Bu veri setinin yetersiz olması durumunda, algoritmaların performansı düşebilir ve hatalı eşlemeler yapılabilir.</p> <p>Bu nedenle, projenin başından itibaren veri seti oluşturulmasına ve bu veri setinin çeşitliliğinin artırılması için çalışmalara başlanması gerekecektir. Fakat bu durum hem ciddi bir iş yükü oluşturmakta hem de bu verilerin temin edilebilmesi çeşitli zorluklar çıkarabilmektedir. Proje planlamasını yaparken yapılan araştırmalar sonucunda veri setine ulaşmada</p>

		yaşanabilecek zorluklardan dolayı çeşitli kaynaklardan elde edilebilecek hazır uydu görüntüsü üzerinden algoritmalar kullanarak bilgisayar tabanlı bir sistem geliştirilmesi planlanmıştır. Ancak projenin ilerleyen aşamalarında oluşturulabilecek veri setinin genişletilmesi, algoritmaların performansını artırmaya yardımcı olabilir. Bu amaçla, farklı ortamlarda ve farklı koşullarda çekilmiş görüntüler veri setine eklenebilir. Ayrıca veri setinin çeşitliliğinin artırılması, algoritmaların performansını artırmaya yardımcı olabilir. Bu amaçla, veri setine farklı türde nesneler ve yapılar içeren görüntüler eklenebilir.
3	Donanım yetersizliği	Projenin başarılı olabilmesi için, yeterli performansa sahip donanıma ihtiyaç vardır. Donanım yetersizliği durumunda, projenin zamanında ve başarılı bir şekilde tamamlanması mümkün olmayabilir. Bu nedenle yine ilk etapta donanıma bağlı geliştirmelerin dışında yazılımsal olarak çalışan bir proje ortaya çıkartılması hedeflenmiştir. Belirli ve kısıtlı ortamlarda projenin çalışmalarına başlanacaktır. İlerleyen süreçlerde projenin durumuna göre stratejik olarak değişikliklere gidilebilecektir. Bu programlardan destek alınması durumunda ilerleyen süreçlerde donanımsal ürünler alınabilecektir. Bu süreçten sonra ise donanım yetersizliğini gidermek için, belirli yöntemler kullanılabilir. Projenin gereksinimlerini karşılayan uygun donanım ve yazılımların temin edilmesi, projenin başarılı bir şekilde tamamlanmasını sağlayacaktır.

3. KAYNAKLAR

1. Shree K. Nayar. (2021). First Principles Of Computer Vision/SIFT. Columbia
2. Random Sample Consensus. (2004-2023).
https://en.wikipedia.org/wiki/Random_sample_consensus
3. Jing Zhang, Guangxue Chen, & Zhaoyang Jia. (2017). An Image Stitching Algorithm Based on Histogram Matching and SIFT Algorithm. International Journal of Pattern Recognition and Artificial Intelligence

4. Guangjun Shi, Yaping Dai & Xiangyang Xu. (2013). SIFT Feature Point Matching Based on Improved RANSAC Algorithm. 2013 5th International Conference on Intelligent Human-Machine Systems and Cybernetics
5. TÜRKİYE'NİN MİLLİ KONUMLAMA VE ZAMANLAMA SİSTEMİ. (2023) <https://www.tualcom.com/trnav-turkiyenin-milli-konumlama-ve-zamanlama-sistemi/>
6. KERKES. (2022) <https://www.stm.com.tr/tr/cozumlerimiz/taktik-mini-ih-sistemleri/kerkes-projesi>
7. Marius Muja & David G. Lowe. (2014). Scalable Nearest Neighbor Algorithms for High Dimensional Data. Pattern Analysis and Machine Intelligence (PAMI), Vol. 36, 2014.
8. Paul-Edouard Sarlin, Daniel DeTone, Tomasz Malisiewicz, Andrew Rabinovich. (2020). SuperGlue: Learning Feature Matching with Graph Neural Networks,2020. <https://arxiv.org/abs/1712.07629>
9. Daniel DeTone, Tomasz Malisiewicz, Andrew Rabinovich. (2018). SuperPoint: Self-Supervised Interest Point Detection and Description, 2018. <https://arxiv.org/pdf/1712.07629>
10. Rémi Pautrat, Iago Suárez, Yifan Yu, Marc Pollefeys, Viktor Larsson. (2023). GlueStick: Robust Image Matching by Sticking Points and Lines Together, 2023. <https://arxiv.org/pdf/2304.02008>
11. Kwang Moo Yi, Eduard Trulls, Vincent Lepetit, Pascal Fua1.(2016). LIFT: Learned Invariant Feature Transform,(2016). <https://arxiv.org/pdf/1603.09114>
12. Christopher B. Choy, JunYoung Gwak, Silvio Savarese, Manmohan Chandraker. (2016). Universal Correspondence Network, (2016). <https://arxiv.org/pdf/1606.03558>

4. EKLER

EK.1. Disiplinler Arası Çalıştay

Çalıştay Grup No: G5

Çalıştay Grup Sorumlusu: Arş.Gör. SEFA KEKLİK

Proje Adı: Bir Bilgisayar Sisteminin İşlem Hızının Artırmak, Enerji Kaybı ve Sıcaklığını Azaltmak

Proje Tanıtımı

Bilgisayar Sisteminin işlem hızını artırmak ve aynı zamanda enerji kaybıyla birlikte sıcaklığını azaltmanın temel amacı daha verimli, dayanıklı ve sürdürülebilir bir çalışma ortamı oluşturmaktır.

STANDARTLAR ve KISITLAR FORMU

Projenin hazırlanmasında uyulan standart ve kısıtlarla ilgili olarak, aşağıdaki soruları cevaplayınız.

1. Projenizin tasarım boyutu nedir? (Yeni bir proje midir? Var olan bir projenin tekrarı mıdır? Bir projenin parçası mıdır? Sizin tasarımınız proje toplamının yüzde olarak ne kadarını oluşturmaktadır?)

Üzerinde halihazırda şirketlerin çalışmalar yaptığı bir problemi ele aldık. Gerçek hayatta var olan bir problemin çözümüne yenilik getirebilmek amacıyla geliştirmeye başladığımız bir proje oldu. Proje, görüntü işleme algoritmaları ve uydu teknolojilerinin etkileşimini içermekte olup, toplam projenin ana bileşenlerinden birini oluşturmaktadır.

2. Projenizde bir mühendislik problemini kendiniz formüle edip, çözdünüz mü? Açıklayınız.

Projenin ana mühendislik problemi, farklı ölçeklerdeki uydu görüntüleri ve İHA tarafından sağlanan canlı görüntüler arasında başarılı bir konum eşleştirmesi yapmak ve bu eşleştirmeleri gerçek harita üzerinde konumlandırmaktır. Bu kapsamda maket şehir üzerinde yaptığımız çalışmalarda ve uydu görüntüleri üzerinde yapılan çalışmalarda gerçek konumun uydu görüntüsü üzerinde belirlenmesi problemi kendimizin formüle edip, çözdüğümüz bir problem idi.

3. Önceki derslerde edindiğiniz hangi bilgi ve becerileri kullandınız?

Görüntü işleme, Algoritma Geliştirme, Yapay Sinir Ağları, Yazılım Mühendisliği, Programlamaya Giriş gibi önceki derslerde edinilen bilgi ve beceriler kullanılmıştır.

4. Kullandığınız veya dikkate aldığınız mühendislik standartları nelerdir? (Proje konunuzla ilgili olarak kullandığınız ve kullanılması gereken standartları burada kod ve isimleri ile sıralayınız).

ISO 9001:2015 Kalite Yönetim Sistemi Standardı
ISO 14001:2015 Çevre Yönetim Sistemi Standardı
ISO 27001:2013 Bilgi Güvenliği Yönetim Sistemi Standardı
IEEE 829:1998 Yazılım Test Teknikleri Standardı

5. Kullandığınız veya dikkate aldığınız gerçekçi kısıtlar nelerdir? Lütfen boşlukları uygun yanıtlarla doldurunuz.

a) Ekonomi

Proje bütçesi sınırlı olduğu için ekonomik bir çözüm bulmak önemlidir. Proje bütçesinin kısıtlı olması gerçek veri setleri üzerinde çalışmamız için önemli bir kısıt oluşturmuştur.

b) Çevre sorunları:

Uydu ve İHA kullanımının çevresel etkileri göz önünde bulundurularak çevresel sürdürülebilirlik sağlanmalıdır.

c) Sürdürülebilirlik:

Projenin uzun vadeli kullanımı ve güncellenmesi düşünülmelidir.

d) Üretilirlik:

Geliştirilen algoritmanın ve sistemlerin endüstri standartlarına uygun bir şekilde üretilir olması önemlidir.

e) Etik:

Kullanıcı gizliliği ve veri güvenliği gibi etik sorunlara saygı gösterilmelidir. Örneğin gerçek zamanlı uydu görüntüleri üzerinde çalışan bir sistemde etik konusundaki kısıtı çok daha fazla önem arz edecektir.

f) Sağlık:

İHA'nın kullanımı sırasındaki sağlık riskleri ve güvenliği göz önünde bulundurulmalıdır. Sağlık alanındaki proje kısıtı doğrudan bu projenin kapsamı içerisindeki bir kısıt değildir.

g) Güvenlik:

İHA ve uydu iletişimi güvenlik standartlarına uygun olmalıdır. Gerçek hayata geçirilmesi durumunda uluslararası alanlarda da projenin kullanılabilineceği göz önünde bulundurulursa güvenlik kısıtı dikkat edilmesi gereken önemli bir gerçek haline gelecektir

h) Sosyal ve politik sorunlar:

Proje, yerel yasal düzenlemelere ve toplumun beklentilerine uygun olmalıdır.

